

Esercizi di autovalutazione sull'uso della libreria pandas

Descrizione dati

I file da utilizzare in questa autovalutazione sono reperibili nel seguente archivio e sono stati scaricati dal sito del Ministero dell'Istruzione e della Ricerca tramite il [link studenti](#) e [link scuole](#). La descrizione del contenuto di ciascuno dei 3 file si trova nei file tracciato ad essi associati.

Esercizio 1

Scrivere un programma in python che implementi le seguenti richieste:

1. Costruire il dataframe `dfClassi` contenente i dati importati dal file `ALUCORSOINDCLASTA20171820180831.csv` assicurandosi che la colonna `ANNOSCOLASTICO` sia di tipo stringa `'str'`.
2. Stampare a video le seguenti informazioni relative al dataframe:
 - nome delle colonne
 - formato dei dati contenuti associati a ciascuna colonna
 - dimensioni del dataframe
 - il numero di scuole (`CODICESCUOLA`) uniche contenute nel dataframe
3. Aggiungere al dataframe `dfClassi` la colonna `ALUNNI` contenente la somma dei valori delle alunne e degli alunni per ciascuna scuola e stampare a video il totale degli alunni presenti nel dataframe.
4. Stampare a video il numero totale di alunne, di alunni presenti in tutte le scuole e la loro somma.
5. Verificare che la stratificazione per `[ 'ANNOSCOLASTICO', 'CODICESCUOLA', 'ANNOCORSOCLASSE' ]` restituisce insiemi composti al massimo da un elemento (identifica record unici).
6. Identificare i valori che la variabile `ANNOCORSOCLASSE` assume nel dataframe.
7. Stampare a video il sommario della popolazione degli alunni divisa per genere e distribuita secondo l'ordine di scuola e la classe frequentata, ovvero, il sommario delle variabili `[ 'ALUNNIFEMMINE', 'ALUNNIMASCHI', 'ALUNNI' ]` stratificato per `ORDINESCUOLA` e `ANNOCORSOCLASSE`.
8. Stampare a video il numero di classi, delle alunne e degli alunni stratificato per `ORDINESCUOLA` e `ANNOCORSOCLASSE`.

Risultato:

ORDINESCUOLA	ANNOCORSOCLASSE	ALUNNIFEMMINE	ALUNNIMASCHI	ALUNNI
SCUOLA PRIMARIA	1	232689	248897	481586
	2	239085	254494	493579
	3	243850	258726	502576
	4	245895	261929	507824
	5	247420	263177	510597
	7	12679	13869	26548
SCUOLA SECONDARIA I GRADO	1	263642	285478	549120
	2	257899	279308	537207
	3	261924	279018	540942
SCUOLA SECONDARIA II GRADO	1	273822	305193	579015
	2	248757	264028	512785
	3	243627	257146	500773
	4	235936	240267	476203
	5	226259	222821	449080
	6	37	214	251

9. Salvare in un file con formato `xlsx` la distribuzione per genere (numero alunne e numero alunni) della popolazione scolastica stratificata per ordine di scuola (`ORDINESCUOLA`) ed anno di corso (`ANNOCORSOCLASSE`)

Esercizio 2

Scrivere un programma in python che implementi le seguenti richieste:

- Costruire il dataframe `dfCittadinanza` contenente i dati importati dal file `ALUITASTRACITSTA20171820180831.csv` assicurandosi che la colonna `ANNOSCOLASTICO` sia di tipo stringa `'str'`.
- Stampare a video le seguenti informazioni relative al dataframe:
 - nome delle colonne
 - formato dei dati contenuti associati a ciascuna colonna
 - dimensioni del dataframe
 - il numero di scuole (`CODICESCUOLA`) uniche contenute nel dataframe
- Verificare che per ogni record, i valori nella colonna `ALUNNICITTADINANZANONITALIANA` corrispondano alla somma dei valori nelle colonne `ALUNNICITTADINANZANONITALIANAPAESIUE` e `ALUNNICITTADINANZANONITALIANAPAESIUE`
- Calcolare il tasso degli alunni per cittadinanza italiana e non italiana rispetto al totale della popolazione alunni
- Calcolare il tasso degli alunni per cittadinanza italiana e non italiana rispetto al totale degli alunni stratificato per ordine della scuola (`ORDINESCUOLA`)

Risultato:

ORDINESCUOLA	aluCitItaRel	aluCitNoltaRel
SCUOLA PRIMARIA	0.883156	0.116844
SCUOLA SECONDARIA I GRADO	0.896737	0.103263
SCUOLA SECONDARIA II GRADO	0.926160	0.073840

Esercizio 3

Scrivere un programma in python che implementi le seguenti richieste:

1. Costruire il dataframe `dfAnagrScuole` contenente i dati importati dal file `SCUANAGRAFESTAT20171820170901.csv` assicurandosi che la colonna `ANNOSCOLASTICO` sia di tipo stringa `'str'`.
2. Stampare a video il nome delle colonne del dataframe `dfAnagrScuole`
3. Modificare il dataframe `dfAnagrScuole` perchè contenga le sole colonne `['AREAGEOGRAFICA', 'REGIONE', 'CODICESCUOLA', 'DENOMINAZIONESCUIOLA']` e verificarlo tramite una stampa a video.
4. stampare a video le seguenti informazioni:
 - formato dei dati contenuti associati a ciascuna colonna
 - dimensioni del dataframe
 - sommario dei dati contenuti nel dataframe
5. Contare il numero di valori distinti della variabile `CODICESCUOLA` presenti nel dataframe
6. Creare una lista contenente le aree geografiche presenti nel dataframe (ciascuna area deve essere presente una sola volta)
7. Creare una lista contenente le regioni presenti nel dataframe (ciascuna regione deve essere presente una sola volta)
8. In Pandas si possono manipolare le stringhe contenute nei record riferendosi all'intera colonna ([metodi per le stringhe](#)). Sfruttando uno dei [metodi per testare le stringhe di una colonna](#), contare il numero delle scuole dedicati a Galileo Galilei, ovvero che contengano la stringa `GALILEI`.

Esercizio 4

Scrivere un programma in python che implementi le seguenti richieste:

1. Costruire il dataframe `dfAnagrScuole` contenente i dati importati dal file `SCUANAGRAFESTAT20171820170901.csv` mantenendo le sole colonne di interesse `['AREAGEOGRAFICA', 'REGIONE', 'CODICESCUOLA', 'DENOMINAZIONESCUIOLA']`.
2. Costruire il dataframe `dfClassi` contenente i dati importati dal file `ALUCORSOINDCLASTA20171820180831.csv` assicurandosi che la colonna `ANNOSCOLASTICO`

sia di tipo stringa `'str'` ed aggiungere una colonna 'ALUNNI' contenente la somma dei valori delle alunne e degli alunni per ciascuna scuola .

3. Costruire il dataframe 'dfClassiGeo' fusione di `dfAnagrScuola` e `dfClassi` usando come variabile per la fusione la colonna `CODICESCUOLA` .
4. Costruire il dataframe `dfClassiGenereGeoSum` contenente la distribuzione per genere dei dati del dataframe `dfClassiGeo` stratificati per Regione.
5. Sfruttando il metodo `.sort_values()` riordinare il contenuto del dataframe `dfClassiGenereGeoSum` . Stampare a video il dataframe ottenuto.
6. Costruire il dataframe `dfClassiGenereAreaSum` contenente la distribuzione per genere dei dati del dataframe `dfClassiGeo` stratificati per Area.
7. Sfruttando il metodo `.sort_values()` riordinare il contenuto del dataframe `dfClassiGenereAreaSum` . Stampare a video il dataframe ottenuto.

Esercizio 5

Scrivere un programma in python che implementi le seguenti richieste:

1. Dati i file `MeteoMilano2011.csv` , `MeteoMilano2012.csv` , `MeteoMilano2013.csv` , `MeteoMilano2014.csv` , `MeteoMilano2015.csv` , si utilizzi un ciclo for che, modificando le stringhe associate ai nomi dei file, costrisca una lista di dataframe. Ciascun elemento di questa lista deve contenere il dataframe con i dati relativi a ciascun anno.
2. Si sfrutti il metodo `.concat()` per concatenare i dati dei vari dataframe in un unico dataframe. Il dataframe risultante deve avere stesso numero di colonne dei dataframe di partenza e numero di righe pari alla somma dei numeri di righe dei dataframe iniziali.